

Trường Đại học Công Nghệ
Viện Trí tuệ nhân tạo



BÁO CÁO SEMINAR KHOA HỌC

**ĐỀ TÀI: Financial Risk Prediction with Profile Tuning on
Pretrained Foundation Models**

Nhóm 10

Giảng viên giảng dạy: Trần Hồng Việt

Sinh viên thực hiện:

Lường Minh Trí- 23020440

Nguyễn Trọng Hồng Phúc - 23020410

Kiều Đức Nam - 23020404

Nguyễn Quang Huy - 22022582

Hà Nội, 12/2024

MỤC LỤC

I. Giới thiệu

II. Mục tiêu

III. Bối cảnh

1. Tầm quan trọng của dự đoán rủi ro tài chính
2. Hạn chế của các phương pháp hiện tại
3. Cơ hội từ LLMs

IV. Phương pháp luận

1. FinPT
2. FinBench
3. Đánh giá

V. Kết quả và phân tích

1. Hiệu suất của FinPT
2. Hiệu quả của điều chỉnh hồ sơ
3. Vai trò của FinBench
4. Hạn chế của LLMs trong phân loại
5. Tác động của mất cân bằng dữ liệu

VI. Đóng góp của nghiên cứu

VII. Ý nghĩa của nghiên cứu

1. Đối với các nhà nghiên cứu
2. Đối với các tổ chức tài chính
3. Đối với cộng đồng AI

VIII. Hạn chế và hướng nghiên cứu

1. Hạn chế
2. Hướng nghiên cứu

IX. Kết luận

MỞ ĐẦU

Dự đoán rủi ro tài chính đóng vai trò quan trọng trong lĩnh vực tài chính. Các phương pháp học máy đã được áp dụng rộng rãi để tự động phát hiện các rủi ro tiềm ẩn và tiết kiệm chi phí. Tuy nhiên, sự phát triển trong lĩnh vực này đang tụt hậu trong những năm gần đây do các thuật toán được sử dụng đã có phần lỗi thời, đặc biệt là trong bối cảnh AI tạo sinh và các mô hình ngôn ngữ lớn (LLM) phát triển nhanh chóng và việc thiếu một chuẩn mực tài chính thống nhất và có nguồn mở đã cản trở các nghiên cứu liên quan trong nhiều năm.

Để giải quyết những vấn đề này, chúng tôi đề xuất FinPT và FinBench: phương pháp trước là một phương pháp mới để dự đoán rủi ro tài chính thực hiện Điều chỉnh hồ sơ trên các mô hình nền tảng được đào tạo trước lớn và phương pháp sau là một tập hợp các tập dữ liệu chất lượng cao về các rủi ro tài chính như vỡ nợ, gian lận và mất khách hàng.

NỘI DUNG

I. Giới thiệu

Bài báo nghiên cứu, được viết bởi Yuwei Yin, Yazheng Yang, Jian Yang và Qi Liu, giới thiệu FinPT (Financial Profile Tuning), một phương pháp tiên phong trong dự đoán rủi ro tài chính bằng cách sử dụng kỹ thuật Điều chỉnh Hồ sơ trên các mô hình nền tảng được huấn luyện trước (pretrained foundation models). Đồng thời, các tác giả đề xuất FinBench, một bộ dữ liệu chuẩn toàn diện để đánh giá các mô hình dự đoán rủi ro tài chính. Bài báo được xuất bản dưới dạng bản thảo trước (preprint) vào năm 2023 bởi Đại học Hồng Kông (HKU) và tập trung vào việc giải quyết hai vấn đề chính trong lĩnh vực tài chính: (1) sự tụt hậu của các thuật toán dự đoán rủi ro so với tiến bộ nhanh chóng của trí tuệ nhân tạo tổng quát (generative AI) và các mô hình ngôn ngữ lớn (LLMs), và (2) sự khan hiếm của các bộ dữ liệu tài chính thống nhất, chất lượng cao. Bằng cách tích hợp xử lý ngôn ngữ tự nhiên (NLP) với phân loại dữ liệu bảng, FinPT mang lại một cách tiếp cận sáng tạo để cải thiện độ chính xác và hiệu quả trong dự đoán rủi ro tài chính.

Bài báo nhấn mạnh vai trò quan trọng của dự đoán rủi ro tài chính trong lĩnh vực ngân hàng và tài chính, nơi các tổ chức cần đánh giá rủi ro liên quan đến khách hàng để đưa ra quyết định sáng suốt. Các phương pháp học máy truyền thống, mặc dù hiệu quả, đã trở nên lỗi thời khi so sánh với khả năng của LLMs hiện đại. FinPT tận dụng sức mạnh của các mô hình như BERT, GPT và LLaMA, kết hợp với một bộ dữ liệu chuẩn mới (FinBench), để nâng cao hiệu suất dự đoán rủi ro tài chính.

II. Mục tiêu

Bài báo đặt ra ba mục tiêu chính:

- Đề xuất FinPT: Phát triển một phương pháp mới chuyển đổi dữ liệu tài chính dạng bảng thành các hồ sơ khách hàng bằng ngôn ngữ tự nhiên, sau đó tinh chỉnh các mô hình nền tảng được huấn luyện trước để dự đoán rủi ro tài chính, bao gồm vỡ nợ (default), gian lận (fraud) và rời bỏ (churn).
- Giới thiệu FinBench: Xây dựng một bộ dữ liệu chuẩn, bao gồm mười tập dữ liệu chất lượng cao từ Kaggle, được tổ chức thống nhất để hỗ trợ nghiên cứu và đánh giá các mô hình dự đoán rủi ro tài chính.
- Đánh giá hiệu quả của FinPT: So sánh hiệu suất của FinPT với các mô hình học máy truyền thống (như RandomForest, XGBoost) và các mạng nơ-ron chuyên dụng (như DeepFM, TabNet) trên FinBench, đồng thời phân tích khả năng áp dụng của LLMs trong các tác vụ tài chính.

III. Bối cảnh

1. Tầm quan trọng của dự đoán rủi ro tài chính

Dự đoán rủi ro tài chính là một nhiệm vụ cốt lõi trong ngành tài chính, giúp các tổ chức đánh giá khả năng khách hàng vi phạm các quy tắc tài chính, chẳng hạn như không trả nợ, gian lận hoặc ngừng sử dụng dịch vụ. Các phương pháp học máy đã được áp dụng rộng rãi để tự động hóa quy trình này, giảm thiểu sai sót con người và tăng hiệu quả. Tuy nhiên, các thuật toán truyền thống như RandomForest hay XGBoost không tận dụng được những tiến bộ mới trong AI, đặc biệt là khả năng xử lý ngôn ngữ tự nhiên của LLMs.

2. Hạn chế của các phương pháp hiện tại

Bài báo chỉ ra hai hạn chế chính trong lĩnh vực dự đoán rủi ro tài chính:

- Thuật toán lỗi thời: Các mô hình học máy truyền thống không thể tận dụng khả năng biểu diễn phức tạp của LLMs, vốn đã chứng minh hiệu quả trong nhiều tác vụ NLP và phân loại văn bản.
- Thiếu dữ liệu chuẩn: Sự khan hiếm của các bộ dữ liệu tài chính thống nhất, công khai đã cản trở nghiên cứu và phát triển các thuật toán mới. Các tập dữ liệu hiện có thường không đồng nhất, thiếu cấu trúc rõ ràng hoặc không đủ lớn để huấn luyện các mô hình phức tạp.

3. Cơ hội từ LLMs

Sự phát triển vượt bậc của các mô hình nền tảng như BERT, GPT-2 và LLaMA đã mở ra cơ hội để cải thiện dự đoán rủi ro tài chính. Các mô hình này, được huấn luyện trên khối lượng dữ liệu văn bản khổng lồ, có khả năng hiểu và xử lý thông tin ngữ nghĩa phức tạp. FinPT tận dụng đặc điểm này bằng cách chuyển đổi dữ liệu bảng thành văn bản ngôn ngữ tự nhiên, cho phép LLMs xử lý thông tin tài chính theo cách giống như xử lý văn bản thông thường.

IV. Phương pháp luận

1. FinPT: Điều chỉnh hồ sơ

FinPT là một quy trình ba bước nhằm chuyển đổi dữ liệu tài chính dạng bảng thành dự đoán rủi ro tài chính thông qua LLMs. Các bước cụ thể bao gồm:

Bước 1: Tạo mẫu hướng dẫn

Dữ liệu bảng (ví dụ: thông tin khách hàng như tuổi, giới tính, thu nhập, điểm tín dụng) được chuyển thành một mẫu hướng dẫn định dạng. Mẫu này có dạng: "Xây dựng một mô tả hồ sơ khách hàng ngắn gọn bao gồm tất cả thông tin sau: [tên cột: giá trị cột; ...]". Ví dụ, một hàng dữ liệu có thể được chuyển thành: "loại khoản vay: ô tô; giới tính: nữ; tuổi: 44; học vấn: trung học; thu nhập: 90215; điểm tín dụng: 676; thời hạn khoản vay: 1; số người ký: 2; quốc tịch: công dân".

Bước 2: Xây dựng hồ sơ

Các hướng dẫn từ bước 1 được đưa vào một LLM mạnh mẽ (như ChatGPT hoặc GPT-4) thông qua API OpenAI. LLM tạo ra một đoạn văn bản ngôn ngữ tự nhiên, mô tả hồ sơ khách hàng một cách mạch lạc và trôi chảy. Ví dụ, từ hướng dẫn trên, LLM có thể tạo ra: "Khách hàng này là một phụ nữ 44 tuổi, đã hoàn thành trung học. Cô ấy là công dân, có thu nhập hàng năm 90.215 USD, điểm tín dụng 676, và đang xin vay mua ô tô với thời hạn 1 năm. Có hai người ký trên đơn xin vay."

Bước 3: Điều chỉnh hồ sơ

Các hồ sơ ngôn ngữ tự nhiên được sử dụng để tinh chỉnh các mô hình nền tảng được huấn luyện trước, chẳng hạn như BERT, GPT hoặc LLaMA. Quy trình tinh chỉnh bao gồm:

- Token hóa: Các hồ sơ văn bản được mã hóa thành token bằng bộ mã hóa chính thức của từng mô hình.
- Tính toán trạng thái ẩn: Mô hình nền tảng xử lý các token để tạo ra trạng thái ẩn (hidden states), biểu diễn ngữ nghĩa của hồ sơ.
- Phân loại: Một mạng nơ-ron tiến nhỏ (thường là mạng feedforward) được thêm vào để dự đoán rủi ro tài chính (nhị phân: 0 - không rủi ro, 1 - có rủi ro) dựa trên trạng thái ẩn.
- Tối ưu hóa: Để giảm chi phí tính toán, một số tham số của mô hình nền tảng được giữ cố định (frozen), đặc biệt với các mô hình lớn như LLaMA. Đối với mô hình mã hóa (encoder-only) như BERT, trạng thái ẩn cuối cùng được trung bình; đối với mô hình giải mã (decoder-only) như GPT, trạng thái ẩn của token cuối cùng được sử dụng.

Hàm mất mát sử dụng Entropy Chéo Nhị phân (BCE) có trọng số để giải quyết vấn đề mất cân bằng dữ liệu, với trọng số cao hơn cho các mẫu tích cực (có rủi ro). Công thức trọng số được tính như sau:

$$[w_{\text{pos}} = \frac{|y| - \sum_i y_i}{\sum_i y_i}]$$

trong đó (y) là nhãn (0 hoặc 1), và ($|y|$) là số lượng mẫu. Hàm mất mát cuối cùng là:

$$[l = -\frac{1}{m} \sum_{i=1}^m [y_i \hat{l}_i w_{\text{pos}} + (1 - y_i) \hat{l}_i]]$$

FinPT cũng hỗ trợ tinh chỉnh trên nhiều tập dữ liệu tài chính đồng thời, tận dụng sự tương đồng giữa các bảng dữ liệu để cải thiện hiệu suất tổng quát. Điều này đặc biệt hữu ích khi các bảng có các cột tương tự (ví dụ: tuổi, thu nhập, điểm tín dụng).

2. FinBench: Bộ Dữ liệu Chuẩn

FinBench là một bộ dữ liệu chuẩn được xây dựng để hỗ trợ nghiên cứu và đánh giá các mô hình dự đoán rủi ro tài chính. Các đặc điểm chính của FinBench bao gồm:

- Nguồn dữ liệu: Được thu thập từ hàng trăm tập dữ liệu trên Kaggle, sau đó chọn lọc mười tập dữ liệu chất lượng cao dựa trên số lượng mẫu, mức độ phổ biến, ý nghĩa của cột và hiệu suất của các mô hình cơ sở.
- Quy mô: Bao gồm khoảng 333.000 mẫu được gán nhãn, chia thành tập huấn luyện (63%), tập xác thực (7%) và tập kiểm tra (30%).
- Cấu trúc thống nhất: Mỗi tập dữ liệu được tổ chức với các thông tin như dữ liệu số (cặp X-y), siêu dữ liệu thống kê (số lớp, số đặc trưng, chỉ số cột số và phân loại), và văn bản hướng dẫn/hồ sơ cho Điều chỉnh Hồ sơ.
- Loại rủi ro: Bao gồm ba loại rủi ro chính:
 - Vỡ nợ (Default):
 - Vỡ nợ tín dụng (Credit Default - CD): Dự đoán việc không trả được hóa đơn thẻ tín dụng. Bao gồm hai tập dữ liệu (cd1, cd2).
 - Vỡ nợ khoản vay (Loan Default - LD): Dự đoán việc không trả được khoản vay (như thế chấp, vay mua xe). Bao gồm ba tập dữ liệu (ld1, ld2, ld3).
 - Gian lận (Fraud): Dự đoán hành vi giả mạo hoặc sử dụng bất hợp pháp. Bao gồm hai tập dữ liệu (cf1, cf2).
 - Rời bỏ (Churn): Dự đoán việc khách hàng ngừng sử dụng dịch vụ. Bao gồm ba tập dữ liệu (cc1, cc2, cc3).
- Mất cân bằng: Tất cả các tập dữ liệu đều mất cân bằng, với tỷ lệ mẫu tích cực (có rủi ro) dao động từ 0.67% (cf1) đến 39.8% (cc2). Điều này đòi hỏi các kỹ thuật cân bằng như trọng số mất mát hoặc lấy mẫu lại.

FinBench được cung cấp thông qua API tải dễ dàng trên HuggingFace, hỗ trợ cả dữ liệu dạng bảng và văn bản, phù hợp cho các thuật toán học máy truyền thống và phương pháp dựa trên NLP như FinPT.

3. Đánh giá

Hiệu suất của FinPT được đánh giá trên FinBench, so sánh với các mô hình cơ sở thuộc ba nhóm:

- Mô hình dựa trên cây (Tree-based): RandomForest, XGBoost, CatBoost, LightGBM. Các mô hình này sử dụng tìm kiếm lưới (grid search) để tối ưu hóa siêu tham số.
- Mạng nơ-ron cho dữ liệu bảng (Neural Networks for Tabular Data): DeepFM, STG, VIME, TabNet. Các mô hình này được huấn luyện từ đầu với khởi tạo trọng số ngẫu nhiên.

- Mô hình nền tảng (Foundation Models): BERT, GPT-2, LLaMA, được tinh chỉnh với FinPT. Hai chiến lược tinh chỉnh được thử nghiệm: tinh chỉnh toàn bộ mô hình (Tune All) và tinh chỉnh chỉ lớp cuối (Tune Last).

Chỉ số đánh giá chính là điểm F1, phù hợp cho các tác vụ phân loại nhị phân với dữ liệu mất cân bằng. Các thí nghiệm cũng khám phá các chiến lược khác như học theo ngữ cảnh (in-context learning - ICL) và tinh chỉnh hướng dẫn (instruction tuning) để đánh giá khả năng của LLMs trong các tác vụ tài chính.

V. Kết quả và Phân tích

1. Hiệu suất của FinPT

FinPT đạt được hiệu suất vượt trội so với các mô hình cơ sở trên tất cả mười tập dữ liệu trong FinBench. Một số điểm nổi bật:

- So với mô hình cây: FinPT vượt qua RandomForest, XGBoost, CatBoost và LightGBM trên hầu hết các tập dữ liệu, đặc biệt trong các tác vụ có tỷ lệ mất cân bằng cao như gian lận (cf1, cf2).
- So với mạng nơ-ron bảng: FinPT vượt trội hơn DeepFM, STG, VIME và TabNet, cho thấy khả năng biểu diễn tốt hơn khi kết hợp dữ liệu văn bản với LLMs.
- Tinh chỉnh đa tập dữ liệu: Khi tinh chỉnh trên tất cả các tập dữ liệu FinBench cùng lúc, FinPT đạt hiệu suất cao hơn so với tinh chỉnh trên từng tập riêng lẻ, chứng minh khả năng tổng quát hóa nhờ sự tương đồng giữa các bảng tài chính.

2. Hiệu quả của điều chỉnh hồ sơ

Việc chuyển đổi dữ liệu bảng thành hồ sơ ngôn ngữ tự nhiên cho phép LLMs tận dụng khả năng hiểu ngữ nghĩa, dẫn đến dự đoán chính xác hơn so với các mô hình xử lý trực tiếp dữ liệu số. Điều này đặc biệt rõ rệt trong các tập dữ liệu có nhiều đặc trưng phân loại (categorical features), như giới tính, học vấn hoặc quốc tịch.

3. Vai trò của FinBench

FinBench cung cấp một nền tảng đánh giá mạnh mẽ, giải quyết vấn đề thiếu dữ liệu chuẩn hóa trong nghiên cứu tài chính. Các đặc điểm như cấu trúc thống nhất, siêu dữ liệu phong phú và hỗ trợ cả dữ liệu số lẫn văn bản khiến FinBench trở thành công cụ lý tưởng cho cả nghiên cứu học thuật và ứng dụng thực tiễn.

4. Hạn chế của LLMs trong phân loại

Mặc dù LLMs được nhắc nhở (prompted) có thể cung cấp lời khuyên tài chính hữu ích, chúng không hiệu quả trong vai trò bộ phân loại trực tiếp so với các mô hình được tinh chỉnh hoặc mô hình cơ sở truyền thống. Điều này cho thấy việc tinh chỉnh là cần thiết để LLMs đạt hiệu suất tối ưu trong các tác vụ tài chính.

5. Tác động của mất cân bằng dữ liệu

Các tập dữ liệu trong FinBench đều mất cân bằng, với tỷ lệ mẫu tích cực thấp (đặc biệt trong gian lận). Hàm mất mát BCE có trọng số và các kỹ thuật cân bằng khác (như lấy mẫu lại) đã cải thiện đáng kể điểm F1, đặc biệt trên các tập dữ liệu như cfl (0.67% mẫu tích cực).

VI. Đóng góp của nghiên cứu

Bài báo mang lại ba đóng góp chính:

1. Phương pháp FinPT: Một cách tiếp cận sáng tạo tích hợp dữ liệu bảng với NLP, tận dụng LLMs để dự đoán rủi ro tài chính. Phương pháp này mở ra hướng mới trong việc áp dụng AI tổng quát vào các tác vụ tài chính.
2. Bộ dữ liệu chuẩn FinBench: Một bộ sưu tập mười tập dữ liệu chất lượng cao, được tổ chức thống nhất và công khai trên HuggingFace, giải quyết vấn đề thiếu dữ liệu chuẩn hóa trong nghiên cứu tài chính.
3. Xác nhận thực nghiệm: Các thí nghiệm toàn diện trên FinBench chứng minh sự vượt trội của FinPT so với các mô hình cơ sở mạnh, đồng thời cung cấp phân tích sâu về ứng dụng của LLMs trong dự đoán rủi ro tài chính.

VII. Ý nghĩa của nghiên cứu

1. Đối với các nhà nghiên cứu

FinPT và FinBench cung cấp một nền tảng vững chắc để thúc đẩy nghiên cứu trong dự đoán rủi ro tài chính. Các nhà nghiên cứu có thể:

- Khám phá các phương pháp tinh chỉnh LLMs khác, chẳng hạn như tinh chỉnh tham số hiệu quả (parameter-efficient fine-tuning).
 - Mở rộng FinBench với các loại rủi ro tài chính khác, như rủi ro thị trường hoặc rủi ro vận hành.
 - So sánh FinPT với các mô hình mới hơn hoặc chuyên biệt cho lĩnh vực tài chính.
- ## 2. Đối với các tổ chức tài chính

FinPT có tiềm năng cải thiện quy trình đánh giá rủi ro trong các tổ chức tài chính bằng cách:

- Tự động hóa: Giảm sự phụ thuộc vào đánh giá thủ công, tiết kiệm thời gian và chi phí lao động.
 - Độ chính xác: Tăng cường khả năng phát hiện rủi ro, đặc biệt trong các tình huống phức tạp hoặc mất cân bằng dữ liệu.
 - Khả năng mở rộng: Áp dụng cho nhiều loại rủi ro tài chính nhờ tính tổng quát của phương pháp.
3. Đối với cộng đồng AI

Nghiên cứu này mở ra một hướng mới trong việc kết hợp dữ liệu bảng với NLP, có thể áp dụng cho các lĩnh vực khác như y tế, tiếp thị hoặc logistics. Việc sử dụng LLMs để xử lý dữ liệu phi văn bản (non-textual data) thông qua chuyển đổi ngôn ngữ tự nhiên là một bước tiến quan trọng trong AI liên lĩnh vực.

VIII. Hạn chế và hướng nghiên cứu tương lai

1. Hạn chế
 - Chi phí tính toán: Tinh chỉnh các mô hình lớn như LLaMA đòi hỏi tài nguyên tính toán đáng kể, có thể không khả thi trong các môi trường hạn chế.
 - Phạm vi dữ liệu: FinBench chỉ bao gồm ba loại rủi ro (vỡ nợ, gian lận, rời bỏ), chưa đại diện cho toàn bộ các rủi ro tài chính.
 - Phụ thuộc vào LLM: Hiệu suất của FinPT phụ thuộc vào chất lượng của các hồ sơ do LLM tạo ra. Nếu LLM không hiểu ngữ cảnh tài chính, hồ sơ có thể thiếu chính xác.
 - Thiếu triển khai thực tế: Các thí nghiệm được thực hiện trên dữ liệu Kaggle, chưa được kiểm chứng trong môi trường tài chính thực tế.
2. Hướng nghiên cứu tương lai
 - Tinh chỉnh hiệu quả: Áp dụng các kỹ thuật như LoRA (Low-Rank Adaptation) để giảm chi phí tính toán khi tinh chỉnh LLMs.
 - Mở rộng FinBench: Thêm các tập dữ liệu cho các rủi ro khác (ví dụ: rủi ro thị trường, rủi ro thanh khoản) và tăng cường đa dạng mẫu.
 - Tích hợp mô hình chuyên biệt: Kiểm tra FinPT với các mô hình được huấn luyện trước cho lĩnh vực tài chính, như FinBERT, để cải thiện hiệu suất.
 - Thử nghiệm thực tế: Triển khai FinPT trong các tổ chức tài chính để đánh giá hiệu quả trong các kịch bản thực tế, bao gồm cả xử lý dữ liệu thời gian thực.
 - Khám phá ICL và Instruction Tuning: Tăng cường nghiên cứu về học theo ngữ cảnh và tinh chỉnh hướng dẫn để giảm nhu cầu tinh chỉnh toàn bộ mô hình.

IX. Kết luận

Bài báo "FinPT: Dự đoán Rủi ro Tài chính với Điều chỉnh Hồ sơ trên các Mô hình Nền tảng được Huấn luyện Trước" mang đến một cách tiếp cận đột phá trong việc áp dụng LLMs vào dự đoán rủi ro tài chính. Bằng cách chuyển đổi dữ liệu bảng thành hồ sơ ngôn ngữ tự nhiên và tinh chỉnh các mô hình như BERT, GPT và LLaMA, FinPT đạt được hiệu suất vượt trội so với các phương pháp truyền thống trên bộ dữ liệu chuẩn FinBench. FinBench, với mười tập dữ liệu chất lượng cao, đáp ứng nhu cầu cấp thiết về một nền tảng đánh giá thống nhất trong nghiên cứu tài chính. Các phát hiện từ nghiên cứu này không chỉ làm sâu sắc thêm hiểu biết về vai trò của LLMs trong các tác vụ tài chính mà còn mở ra các cơ hội mới để tích hợp NLP với xử lý dữ liệu bảng trong nhiều lĩnh vực khác. Với những đóng góp đáng kể và tiềm năng ứng dụng rộng rãi, FinPT và FinBench hứa hẹn sẽ định hình tương lai của dự đoán rủi ro tài chính và nghiên cứu AI liên lĩnh vực.